Bases de Datos I

Facultad de Prrocesamiento y Optimización de XOCLOS consultas





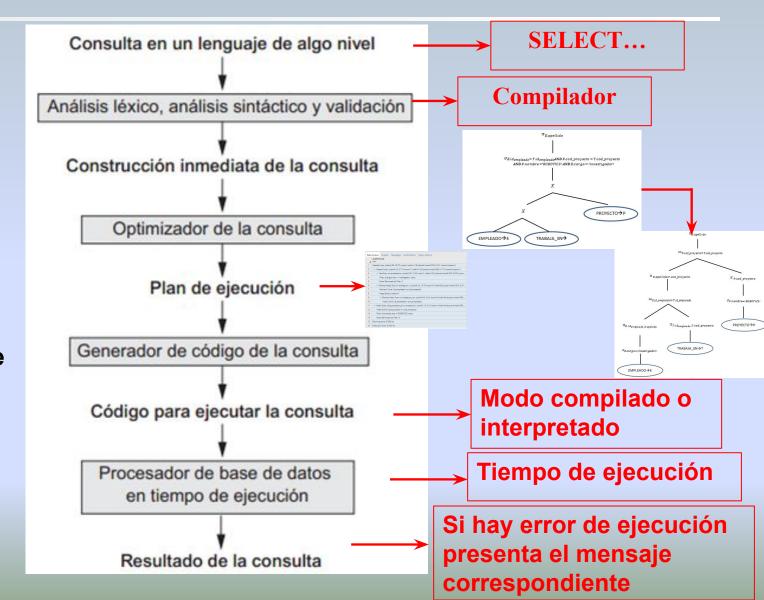
Introducción

- Comprender las tareas de procesamiento y optimización de consultas realizadas por un SGBD.
- Conocer las reglas heurísticas y de transformación de expresiones del álgebra relacional y cómo aplicarlas para mejorar la eficiencia de una consulta.
- Conocer las diferentes estrategias de implementación de operaciones relacionales, en particular la de ensamble, y cómo evaluar el costo estimado de cada estrategia.
- Identificar la información estadística de la base utilizada para estimar el costo de ejecución de las operaciones del álgebra relacional.

Introducción



Elmasri, R.; Navathe, S.B.: Fundamentos de Sistemas de Bases de Datos. 5ª Edición. Addison-Wesley. (Cap. 15)



Procesamiento y Optimización de Consultas

Objetivos del procesamiento de consultas

- Transformar una consulta SQL en una **estrategia de ejecución eficaz**, expresada en un lenguaje de bajo nivel.
- Ejecutar dicha estrategia para recuperar los datos requeridos.

Optimización de Consultas: Elección de una estrategia de ejecución eficaz para procesar. Puede haber muchas <u>transformaciones equivalentes</u> para una misma consulta.

Objetivo de la optimización de consultas

- Elegir la estrategia de ejecución que minimiza el uso de los recursos
- En general, no se garantiza que la estrategia elegida por el SGBD sea la <u>óptima</u>, pero seguro que será una estrategia razonablemente eficiente

Procesamiento y Optimización de Consultas

Ventajas de la optimización automática

- El usuario no se preocupa de cómo formular la consulta
- El Módulo Optimizador trabaja "mejor" (a veces!!!) que el DBA o programador, pues:
 - Dispone de información estadística en el diccionario de datos del SGBD
 - Estimar mejor la eficiencia de cada posible estrategia... y así (con mayor probabilidad) elegirá la más eficiente.
 - Si cambian las estadísticas (por ej. si se reorganiza el esquema de BD)
 - 4 Re-optimización (quizá ahora convenga elegir otra estrategia)
 - SGBD Relacional o post-relacional: El Optimizador re-procesa la consulta original
 - SGBD No Relacional: hay que modificar el software!
 - Por lo general el Optimizador por ser un módulo del SGBD puede considerar más estrategias que un DBA manualmente.

PyOC: Análisis léxico, sintáctico y validación

Nombres de los voluntarios que realizan la tarea de PROMOCION SELECT nombre FROM voluntario V, tarea T WHERE V.id_tarea = T.id_tarea AND T.nombre_tarea='PROMOCION';

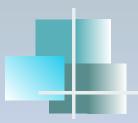


 $\Pi_{\text{nombre}}(\sigma_{\text{V.id_tarea}} = \text{T.id_tarea AND nombre_tarea} = \text{`PROMOCION'}(\text{VOLUNTARIO X TAREA}))$

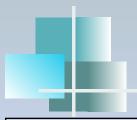
PyOC: Análisis léxico, sintáctico y validación

Π_{nombre}(σ_{V.id_tarea} = T.id_tarea AND nombre_tarea='PROMOCION' (VOLUNTARIO X

Árbol de Consulta(o árbol sintáctico abstracto)
es la representación de
una expresión algebraica



- El Optimizador de Consultas suele combinar varias técnicas, las principales son las siguientes:
 - -Optimización heurística: Ordena las operaciones de la consulta para incrementar la eficiencia de su ejecución
 - -Estimación de costos:
 - Estima el costo de cada estrategia de ejecución y
 - Elige un plan (estrategia) con el menor costo estimado



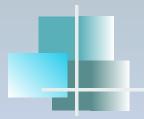
Optimización Heurística

Implica aplicar de **reglas de transformación y heurísticas** para modificar la representación interna de una consulta (Álgebra Relacional o **Árbol de consulta**) a fin de mejorar su rendimiento

- El Optimizador selecciona el plan de ejecución más económico
- En general, existen muchos (¡demasiados!) posibles planes de ejecución para una consulta

La tarea de **obtener el plan más económico**, **tendría un costo elevado**...

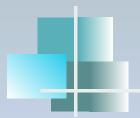
Entonces se suelen utilizar **técnicas heurísticas** para mantener el conjunto de planes de consulta generados en una cantidad razonable.



- El Analizador Sintáctico genera árbol de consulta inicial
 - sin optimización ⇒ ejecución ineficiente
- El Optimizador de Consultas transforma el árbol de consulta inicial en árbol de consulta final equivalente y eficiente

Aplicación de **reglas de transformación** guiadas por **reglas heurísticas**

Conversión de la consulta en su **forma canónica equivalente**



 Obtenida la forma canónica de la consulta, el Optimizador decide cómo evaluarla

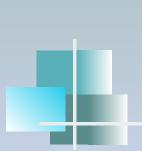
Estimación sistemática de costos:

Estimación y comparación de los **costos de ejecutar** una consulta con **diferentes estrategias**, y elegir la estrategia con menor costo estimado

 El punto de partida es considerar la consulta como una serie de operaciones elementales interdependientes

Operaciones del Álgebra Relacional: π , σ \bowtie , \cup , \cap

El Optimizador tiene un conjunto de técnicas para realizar cada operación

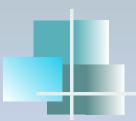




Información estadística

- Para cada tabla
 - Cardinalidad (cant.filas), Factor de bloqueo (cant. de filas por bloque), bloques ocupados,
 - Método de acceso primario y otras estructuras de acceso (hash, índices,etc.),
 - Columnas indexadas, de dispersión, de ordenamiento (físico o no), etc.
- Para cada columna
 - Nº de valores distintos almacenados,
 - Valores máximo y mínimo, etc.

El **éxito** de la estimación del **tamaño** y **costos** de las operaciones incluidas en una consulta, depende de la cantidad y actualidad de la información estadística almacenada en el diccionario de datos del SGBD



- Método heurístico de optimización de consultas utiliza reglas de transformación para convertir una expresión de álgebra relacional en otra forma equivalente que sepa que es más eficiente.
- Utiliza las reglas de transformación para **reestructurar** el árbol de álgebra relacional canónico.
- Construcción árbol canónico, se obtiene de aplicar:
 - 1. Producto cartesiano (X) a relaciones del FROM
 - 2. Condiciones de selección y ensamble de la cláusula WHERE
 - 3. Proyección sobre los atributos de la cláusula SELECT.



Nombres de los voluntarios que mayores de 18 años y que realizan la tarea de PROMOCION

SELECT nombre

FROM voluntario V, tarea T

WHERE V.id_tarea = T.id_tarea

AND T.nombre tarea='PROMOCION'

AND data want/hazard and // facility and

AND date_part('year',age(V.fecha_nacimiento)) > 18;

C1

C2 C3 Á

Árbol canónico desarrollado en

clase

$$\Pi_{\text{nombre}}(\mathbf{O}_{\text{C2 AND C3}}(V \bowtie T))$$

$$\Pi_{\text{nombre}}(((\sigma_{C3}(V))) \bowtie (\sigma_{C2}(T)))....Otros!!$$

1. Selección Conjuntiva: una secuencia de selecciones sobre una relación A puede transformarse en una sola selección

$$\sigma_{c1}(\sigma_{c2}(A)) \equiv \sigma_{c1 \text{ AND } c2}(A)$$

2. La selección es conmutativa,

$$\sigma_{c1}(\sigma_{c2}(A)) \equiv \sigma_{c2}(\sigma_{c1}(A))$$

3. En una secuencia de proyecciones sobre una relación A pueden ignorarse todas, salvo la última (si cada columna mencionado en la última, también aparece en las demás)

$$\Pi_{L2}(\Pi_{L1}(A)) \equiv \Pi_{L2}(A)$$
, sii $L2 \subseteq L1$

4. La selección, puede combinarse con productos cartesianos y ensambles generales (Theta join).

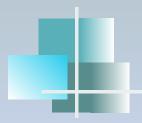
$$\sigma_{c1}(A \times B) \equiv (A_{\bowtie c1} B) \qquad \sigma_{c1}(A_{\bowtie c2} B) \equiv A\bowtie_{c1 AND C2} B$$

5. Los ensambles naturales y generales son conmutativos.

$$A_{\bowtie c}B \equiv B_{\bowtie c}A$$

6. a) Los ensambles naturales y b) generales son asociativos

a) (A B)
$$C \equiv A$$
 (B C)
b) (A B) $C_{1} = A$ (B C)
c2 involucra atributos sólo de B y C



- 7. O es distributiva respecto de ensambles si la condición de selección ...
 - C1 involucra sólo atributos de una de las expresiones a ensamblar (sea A)

$$\sigma_{c1}(A \bowtie_{c} B) \equiv (\sigma_{c1}(A)) \bowtie_{c} B$$

C1 involucra sólo los atributos de A y C2 sólo los de B.

$$\sigma_{c_1 \text{ AND } c_2}(A_{\bowtie c}B) \equiv (\sigma_{c_1}(A))_{\bowtie c} (\sigma_{c_2}(B))$$

se reduce el número de filas examinadas en la siguiente operación en secuencia: join (así, esa operación será más rápida y también producirá menos filas)

se reduce el nro. de columnas que se involucran en la siguiente operación en secuencia: join (por tanto, esa operación necesitará menos tiempo para su ejecución y producirá menos columnas)

Reglas de Equivalencia

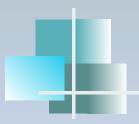
- 8. π es distributiva para el ensamble general si:
 - si π involucra sólo atributos de L1 \cup L2 (L1 y L2 conj. de atributos de A y B, L1 \cap L2 \neq \emptyset)

$$\pi_{\text{L10 L2}}(A \bowtie_{c} B) \equiv (\pi_{\text{L1}}(A)) \bowtie_{c} (\pi_{\text{L2}}(B))$$

■ L1, L3 y L2, L4 conj. de atributos de A y B respectivamente; L3 y L4 involucrados en la condición C, pero no en L1 U L2.

$$\pi_{L1 \cup L2} (A \bowtie_{\mathbb{C}} B) \equiv$$

$$(\pi_{L1 \cup L2} ((\pi_{L1 \cup L3} (A)) \bowtie_{\mathbb{C}} (\pi_{L2 \cup L4} B))$$



 Son conmutativas: UNIÓN e INTERSECCIÓN y NO conmutativas: DIFERENCIA y DIVISIÓN

$$A \cup B \equiv B \cup A$$
 $A \cap B \equiv B \cap A$

 Son asociativas: UNIÓN e INTERSECCIÓN y NO asociativas: DIFERENCIA y DIVISIÓN

(A
$$\cup$$
B) \cup C \equiv A \cup (B \cup C) (A \cap B) \cap C \equiv A \cap (B \cap C)

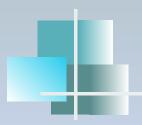
se reduce el número de filas examinadas en la siguiente operación en secuencia: Θ (así, esa operación será más rápida y también producirá menos filas)

Reglas de Equivalencia

11. π es distributivo respecto de la U

$$\pi_{P}(A \cup B) \equiv (\pi_{P}(A)) \cup (\pi_{P}(B))$$

12. σ es distributivo respecto de la U, Ω y – ; $\Theta \in \{ \cup, \cap, - \}$ $\sigma_c(A\ThetaB) \equiv (\sigma_c(A)) \Theta(\sigma_c(B))$

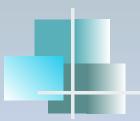


• Expresiones de cómputo escalar

- El Optimizador debe conocer reglas de transformación de expresiones aritméticas porque aparecen en las consultas
- Reglas de transformación basadas en propiedades Conmutativa,
 Asociativa y Distributiva

Expresiones condicionales (booleanas)

- El Optimizador debe saber aplicar reglas generales a operadores
 - de comparación (>, <, ...) y</p>
 - lógicos (AND, OR, ...)



Reglas Heurísticas

Algunas **buenas heurísticas** que pueden ser aplicadas durante el procesamiento de consultas

- 1. Ejecutar operaciones de restricción O tan pronto como sea posible
- 2. Ejecutar **primero las restricciones O más restrictivas** (las que producen menor nro. de filas)
- 3. Combinar un producto cartesiano × con una σ subsiguiente cuya condición represente una condición de reunión, convirtiéndolas en un ensamble
- 4. Ejecutar las operaciones de Π tan pronto como sea posible



Implementación de op. relacionales

Sin índices: Los algoritmos que 'barren' tablas (archivos) recuperando registros que cumplen con la condición de la selección.

Algoritmos básicos:

- Búsqueda lineal: Se examinan todos los bloques y se toman los que cumplan la condición.
- Búsqueda binaria: Si el archivo está ordenado en función del atributo del que se está realizando la selección.

Con indices:

- Igualdad basada en clave: Se usará el índice primario para recuperar el único registro.
- o **Igualdad basada en atributo no clave:** Se usará el índice de agrupamiento para recuperar varios registros.
- Otros casos de igualdad: Utilizar índices secundarios para recuperar un registro si es único o varios si no lo es.



Implementación de op. relacionales

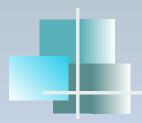
Sin índices: Debe barrer todo el archivo (tabla).

Con índice sobre el atributo de selección: Se utilizará el índice para encontrar el conjunto de entradas que satisfacen la condición, y luego se recuperarán los registro de datos.

Importante: el índice con hash sólo es eficiente para selecciones por igualdad

Estimación del tamaño del resultado:

(Tamaño de V) * factor de reducción



Operación de Selección

Algoritmos de búsqueda para localizan y recuperan registros de archivos con br bloques y su costo en términos de operaciones E/S

- Búsqueda lineal: br
- **Búsqueda binaria:** [log₂ (br)], archivo ordenado según un atributo y condición de la selección.

Con Caminos de acceso (índices)

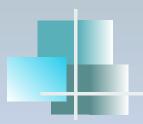
- Índice primario: Altura del árbol + 1
- Índice secundario: Altura del árbol + n registros

Con condiciones de comparación σ A <= x (T)

• índice primario o secundario de comparación: Si A >= x

Con ensambles

- Por bucle
- Por bucle indexado
- Por ordenación-mezcla



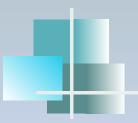
Plan de ejecución de la consulta

Algunos SGBD permiten a los usuarios inspeccionar la estrategia del optimizador para ejecutar determinada consulta.

Algunos SGBD permiten "fijar" el plan de consulta. (hints) Postgresql NO.

Query execution plan:

En Postgresql sentencia **EXPLAIN** EXPLAIN SELECT



Bibliografía

Elmasri, R.; Navathe, S.B.: **Fundamentos de Sistemas de Bases de Datos**. 3ª Edición. Addison-Wesley. **(Cap. 18)**

Elmasri, R.; Navathe, S.B.: **Sistemas de bases de datos. Conceptos fundamentales**. 2ª Ed. Addison-Wesley Iberoamericana. **(Cap. 16)**

Connolly et al.: **Database Systems: A Practical Approach to Design, Implementation and Management**. 2nd Ed.
Addison-Wesley (Cap. 18)